




Ev Fiyatları Tahmin Modeli



Makine Öğrenmesi ile Ames Housing Veri
Seti Analizi ve Karşılaştırmalı Model Sonuçları



Hazırlayanlar

- SEMİH ERTAN
- ZEYNEP NUR DİRİK
- MUHAMMET FAİK DUMAN
- MEHMET EMİRHAN OĞUZ

Proje Amacı ve Problem Tanımı

Hedefimiz

Bu değişkenler arasındaki gizli ilişkileri bularak, bir evin satış fiyatını en düşük hata payı ile tahmin eden en iyi makine öğrenmesi modelini geliştirmek.

1460 Adet
Eğitim Verisi (Ev)

01

Veri Kaynağı: Kaggle Ames Housing Dataset (Ames, Iowa, ABD).
Kapsam: 2006-2010 yılları arasındaki konut satış verileri.

02

Veri Yapısı: Her bir ev için 79 farklı değişken (öznitelik).

03

Fiziksel Özellikler: Metrekare, oda sayısı, bodrum tipi vb..

04

Kalite Puanları: Malzeme kalitesi, ısıtma sistemi, mutfak durumu

05

Konum Bilgisi: Semt, cadde bağlantısı, manzara.


06

Hedef Değişken (Target): Konutun son satış fiyatı (SalePrice).

07

Yöntem: Denetimli Öğrenme (Supervised Learning) - Regresyon Problemi.

Veriyi Önizleme



```
### 1. VERİNİN İLK 5 SATIRI (df.head()) ###
```

	Id	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	Utilities	LotCon
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvl	AllPub	Ins
1	2	20	RL	80.0	9600	Pave	NaN	Reg	Lvl	AllPub	
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvl	AllPub	Ins
3	4	70	RL	60.0	9550	Pave	NaN	IR1	Lvl	AllPub	Con
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	AllPub	

Veriyi Önizleme



df.info() çıktısı bize verinin genel haritasını çıkardı. Toplam 1460 satırımız ve 81 sütunumuz var.

```
### 2. VERİ YAPISI VE TİPLERİ (df.info()) ###
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 81 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   Id                    1460 non-null  int64  
1   MSSubClass            1460 non-null  int64  
2   MSZoning              1460 non-null  object  
3   LotFrontage          1201 non-null  float64 
4   LotArea              1460 non-null  int64  
5   Street               1460 non-null  object  
6   Alley                91 non-null    object  
7   LotShape             1460 non-null  object  
8   LandContour          1460 non-null  object  
9   Utilities            1460 non-null  object  
10  LotConfig            1460 non-null  object  
11  LandSlope            1460 non-null  object  
12  Neighborhood         1460 non-null  object  
13  Condition1           1460 non-null  object  
14  Condition2           1460 non-null  object  
15  BldgType             1460 non-null  object  
16  HouseStyle           1460 non-null  object  
17  OverallQual          1460 non-null  int64
```

Kritik Keşif

- Gördüğünüz gibi, bazı sütunlarda (örneğin LotFrontage'da sadece 1201 dolu veri var, gerisi eksik) ciddi oranda veri kaybı mevcut.
- PoolQC (Havuz Kalitesi) gibi sadece 7 dolu veri olan sütunlar da var. Bu eksiklikleri doğru strateji ile doldurmak zorundayız.
- Ayrıca MSSubClass gibi sayısal görünen bazı sütunların aslında evin tipini belirten kategorik kodlar olduğunu anladık. Bu tür yanlış tipleri (sayısal görünümlü kategorik veriler) dönüştürmemiz gerektiğini belirledik.

Veriyi Önizleme

3. İSTATİSTİKSEL ÖZET (df.describe())

	count	mean	std	min	25%	50%	75%	max
Id	1460.0	730.500000	421.610009	1.0	365.75	730.5	1095.25	1460.0
MSSubClass	1460.0	56.897260	42.300571	20.0	20.00	50.0	70.00	190.0
LotFrontage	1201.0	70.049958	24.284752	21.0	59.00	69.0	80.00	313.0
LotArea	1460.0	10516.828082	9981.264932	1300.0	7553.50	9478.5	11601.50	215245.0
OverallQual	1460.0	6.099315	1.382997	1.0	5.00	6.0	7.00	10.0
OverallCond	1460.0	5.575342	1.112799	1.0	5.00	5.0	6.00	9.0
YearBuilt	1460.0	1971.267808	30.202904	1872.0	1954.00	1973.0	2000.00	2010.0
YearRemodAdd	1460.0	1984.865753	20.645407	1950.0	1967.00	1994.0	2004.00	2010.0
MasVnrArea	1452.0	103.685262	181.066207	0.0	0.00	0.0	166.00	1600.0
BsmtFinSF1	1460.0	443.639726	456.098091	0.0	0.00	383.5	712.25	5644.0
BsmtFinSF2	1460.0	46.549315	161.319273	0.0	0.00	0.0	0.00	1474.0
BsmtUnfSF	1460.0	567.240411	441.866955	0.0	223.00	477.5	808.00	2336.0
TotalBsmtSF	1460.0	1057.429452	438.705324	0.0	795.75	991.5	1298.25	6110.0
1stFlrSF	1460.0	1162.626712	386.587738	334.0	882.00	1087.0	1391.25	4692.0
2ndFlrSF	1460.0	346.992466	436.528436	0.0	0.00	0.0	728.00	2065.0
LowQualFinSF	1460.0	5.844521	48.623081	0.0	0.00	0.0	0.00	572.0
GrLivArea	1460.0	1515.463699	525.480383	334.0	1129.50	1464.0	1776.75	5642.0
BsmtFullBath	1460.0	0.425342	0.518911	0.0	0.00	0.0	1.00	3.0
BsmtHalfBath	1460.0	0.057534	0.238753	0.0	0.00	0.0	0.00	2.0
FullBath	1460.0	1.565068	0.550916	0.0	1.00	2.0	2.00	3.0
HalfBath	1460.0	0.382877	0.502885	0.0	0.00	0.0	1.00	2.0
BedroomAbvGr	1460.0	2.866438	0.815778	0.0	2.00	3.0	3.00	8.0

01

Bu tablo, sayısal verilerimizin dağılımını gösteriyor. Özellikle hedefimiz olan SalePrice (Satış Fiyatı) sütununa odaklandık. Ortalama ev fiyatı yaklaşık \$180,921 civarındadır.

02

Std (standart sapma) ve max değerlerine baktığımızda (SalePrice için max değer \$755,000'a kadar çıkıyor), veri setinde aykırı değerlerin olduğunu anladık.

03


Aynı zamanda GrLivArea (Yaşam Alanı) veya LotArea (Arsa Alanı) gibi özelliklerin ortalama ve medyan değerleri (50% satırı) arasındaki büyük fark, bu özelliklerin de çarpık dağıldığını ve ön işleme ihtiyacı olduğunu gösterdi.

Veriyi Önizleme

Sağa Çarpık Dağılım (Skewness)


Veri setini ilk incelediğimizde, ev fiyatlarının normal dağılım göstermediğini fark ettik.

Çoğu ev düşük-orta fiyat bandındayken, az sayıda çok pahalı ev "kuyruk" oluşturuyordu.



Veriyi Önizleme → Normalizasyon

Çözüm




Logaritmik Dönüşüm

Modellerin sağlıklı öğrenebilmesi için hedef değişken (SalesPrice) normalleştirildi.

$\text{Log}(1+x)$ dönüşümü uygulandı.

Bu işlem, modelin yüksek fiyatlı evlerdeki tahmin hatasını ciddi oranda düşürdü.



Fiyatı en çok etkileyen öznitelikler

01

Pozitif Korelasyonlar (Fiyatı Artıran Faktörler)

OverallQual (Genel Kalite) : Yaklaşık 0.80 gibi yüksek bir korelasyonla açık ara birinci sırada yer alır. Bu, bir evin fiyatını belirleyen en önemli tekil faktörün malzemenin ve işçiliğin kalitesi olduğunu gösterir.

GrLivArea (Yaşam Alanı) : İkinci sırada yer alması beklenen bir sonuçtur. Evin büyüklüğü fiyatı doğrudan etkiler.


GarageCars (Garaj Kapasitesi) ve GarageArea (Garaj Alanı) : Bu iki özelliğin de yüksek korelasyona sahip olması, garajın büyüklüğü ve kapasitesinin alıcılar için ne kadar önemli olduğunu gösterir.

02

Negatif Korelasyonlar (Fiyatı Düşüren Faktörler)

EnclosedPorch (Kapalı Sundurma) : Bu tür eski tip sundurmaların artması, fiyatı olumsuz etkiler. Bu genellikle evin daha eski olduğu ve modern beklentileri karşılamadığı anlamına gelir.

MSSubClass (Bina Tipi Kodu) : Bu özellik negatif bir korelasyon gösterir. Bu, makine öğrenmesi modelinin, bu kodun temsil ettiği eski veya daha az popüler konut tiplerini (örneğin 30, 45 kodları) otomatik olarak düşük fiyatla ilişkilendirdiği anlamına gelir.




Yaşam Alanı

Yerüstü yaşam alanı (GrLivArea).
Metrekare arttıkça fiyat doğrusal
olarak artıyor.




Genel Kalite

Evin malzeme ve işçilik kalitesi (1-10
puan). Fiyatla en yüksek korelasyona
sahip özellik.



Konum (Semt)


'StoneBr' ve 'NridgHt' gibi semtler,
diğer bölgelere göre belirgin şekilde
daha değerli.



İlişki (Trend)

Grafiğe bakıldığında pozitif bir korelasyon (ilişki) görülmektedir.

Yani genel olarak evin yaşam alanı büyüdükçe, satış fiyatı da artma eğilimindedir.



Scatter Plot (Saçılım Grafiği)


Güçlü Pozitif İlişki: Kalite puanı (X eksen) arttıkça, medyan satış fiyatı (kutunun içindeki çizgi) belirgin bir şekilde artıyor.

Belirsizlik Artışı: Kalite puanı düşükken (1-4 arası) kutular çok kısadır; yani fiyatlar birbirine çok yakındır, sürpriz azdır.

Ancak kalite puanı yükseldikçe (özellikle 9 ve 10'da) kutular uzuyor.


Bu, lüks evlerde fiyat aralığının çok geniş olduğunu, aynı kalitedeki iki evin fiyatı arasında uçurum olabileceğini gösterir.

10 Numaranın Farkı: 10 puanlık evlerin hem taban fiyatı çok yüksek hem de tavan fiyatı çok değişkendir.



Box Plot (Kutu Grafiği)

Box Plot (Kutu Grafiği)



"Grafğin sol tarafında 'MeadowV' ve 'IDOTRR' gibi daha ekonomik ve fiyat aralığı dar (standart) semtleri görürken; sağa doğru ilerledikçe 'NoRidge' ve 'NridgHt' gibi lüks ve fiyat çeşitliliği yüksek bölgelere geçiş yapıyoruz."

"Semtler arasındaki bu net basamaklanma, bize evin bulunduğu mahallenin, fiyat üzerinde ne kadar ayırt edici bir etkisi olduğunu kanıtıyor."

Eksik Verilerin Yönetimi (Missing Values)

STRATEJİ -A

A

“Yok”
Anlamına
Gelenler

Açıklama

"Havuz, Çit, Şömine gibi özelliklerdeki boşluklar (NaN), aslında veri kaybı değil, o özelliğin evde bulunmadığı anlamına geliyordu. Bu yüzden bunları 'Yok' (None) kategorisiyle doldurduk.

Uygulama (Ne Yaptık?)

Kategorik veriler için boşlukları "None" (Yok) adlı yeni bir kategori ile doldurduk. Sayısal veriler için (örn: Havuz olmayan evin havuz alanı) boşlukları 0 ile doldurduk.

Sayısal (10 Adet)

GarageYrBlt, GarageArea, GarageCars (Garajsız evlerin garaj yılı/alanı 0), BsmtFinSF1, BsmtFinSF2, BsmtUnfSF, TotalBsmtSF, BsmtFullBath, BsmtHalfBath (Bodumsuz evlerin alanları 0), MasVnrArea.

Etkilenen Öznitelikler (Toplam 25 Değişken)

Kategorik (15 Adet): PoolQC (Havuz) MiscFeature (Diğer), Alley (Yol), Fence (Çit) FireplaceQu (Şömine), GarageType, GarageFinish, GarageQual, GarageCond (Garaj Özellikleri), BsmtQual, BsmtCond, BsmtExposure, BsmtFinType1, BsmtFinType2 (Bodrum Özellikleri), MasVnrType (Duvar Kaplama).

Eksik Verilerin Yönetimi (Missing Values)

STRATEJİ -B

B

Mantıksal Doldurma (LotFrontage)

Açıklama: "Evin caddeye bakan cephesi (LotFrontage)cadde cephesi uzunluğu eksik olamazdı. Bu veriyi rastgele doldurmak yerine, evin bulunduğu semtteki diğer evlerin medyan cephe değerini kullanarak doldurduk. Çünkü aynı mahalledeki evlerin parsel yapıları benzerdir.

Etkilenen Öznitelikler (1 Kritik Değişken):

LotFrontage: Doğrudan evin değerini ve arsa payını etkileyen kritik bir değişkendir. Bu yöntemle yaklaşık 259 adet eksik veri, gerçeğe en yakın şekilde kurtarılmıştır.

Eksik Verilerin Yönetimi (Missing Values)

STRATEJİ -C

C

Mod (En Sık Görülen) ile Doldurma

Açıklama: "Elektrik sistemi, Mutfak kalitesi gibi sadece 1-2 satırda eksik olan verileri, geneli bozmamak adına veri setindeki en yaygın değer ile doldurduk.


Etkilenen Öznitelikler (8 Değişken):

Electrical (Elektrik), MSZoning (İmar Tipi), KitchenQual (Mutfak Kalitesi), Exterior1st, Exterior2nd (Dış Kaplama), SaleType (Satış Türü), Utilities (Altyapı), Functional (Ev Fonksiyonelliği).

Aykırı Değerlerin (Outliers) Temizlenmesi



Yaşam Alanı (GrLivArea) vs. Satış Fiyatı



- Yaşam alanı (GrLivArea) 4000 metrekare üzerinde olan ancak fiyatı anormal derecede düşük (300.000\$'dan az) olan 2 evi veri setinden çıkardık.
- "Veri setinde çok büyük ama çok ucuz evler olduğunu fark ettik (muhtemelen tarım arazisi veya özel durumlu satışlar)."
- Bu uç değerler, modelimizin genel trendi öğrenmesini engelliyor ve gürültü yaratıyordu. Bunları temizleyerek modelin doğruluğunu artırdık."

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ -1

Yanıltıcı Sayısal Verilerin Düzeltilmesi (Type Transformation)

MANTIK

Veri setindeki bazı sütunlar sayısal görünse de aslında sayısal bir büyüklük ifade etmiyordu. Örneğin: MSSubClass sütunu. Burada "20", "60" gibi değerler var. Ancak "60" (2 katlı ev), "20" (1 katlı ev)'den matematiksel olarak "3 kat büyüktür" diyemeyiz. Bunlar sadece birer koddur. Eğer bunları sayı olarak bıraksaydık, model yanlış bir matematiksel ilişki (büyüklük-küçüklük) kurmaya çalışacaktı.

UYGULAMA

Bu sütunları sayısal (integer) formatından metin (string) formatına çevirerek modele "Bunları kategori olarak gör" dedik.

ETKİLENEN ÖZELLİKLER

MSSubClass (Konut Tipi Kodu), OverallCond (Bazen kategorik ele alınabilir), YrSold, MoSold (Tarihler bazen kategori olarak daha iyi çalışır).

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ-1

MSSubClass: Identifies the type of dwelling involved in the sale.

20	1-STORY 1946 & NEWER ALL STYLES
30	1-STORY 1945 & OLDER
40	1-STORY W/FINISHED ATTIC ALL AGES
45	1-1/2 STORY - UNFINISHED ALL AGES
50	1-1/2 STORY FINISHED ALL AGES
60	2-STORY 1946 & NEWER
70	2-STORY 1945 & OLDER
75	2-1/2 STORY ALL AGES
80	SPLIT OR MULTI-LEVEL
85	SPLIT FOYER
90	DUPLEX - ALL STYLES AND AGES
120	1-STORY PUD (<u>Planned Unit Development</u>) - 1946 & NEWER
150	1-1/2 STORY PUD - ALL AGES
160	2-STORY PUD - 1946 & NEWER
180	PUD - MULTILEVEL - INCL SPLIT LEV/FOYER
190	2 FAMILY CONVERSION - ALL STYLES AND AGES

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ-2

Sıralı (Ordinal) Kategorilerin Puanlanması (Label Encoding)

MANTIK

Bazı kategorik verilerde doğal bir sıralama vardı.
Örneğin: Mutfak Kalitesi (KitchenQual). "Excellent (Ex)" > "Good (Gd)" > "Typical (TA)".
Burada One-Hot Encoding (0-1) yapsaydık, "Mükemmel" in "İyi" den daha üstün olduğu bilgisini kaybederdik.
Modelin bu kalite artışını anlaması gerekiyordu.

UYGULAMA

Bu özellikleri, kalite seviyesine göre 0'dan 5'e kadar puanladık.
Ex (Mükemmel) = 5, Gd (İyi) = 4 ... Po (Kötü) = 1, None (Yok) = 0.

ETKİLENEN ÖZELLİKLER

Kalite Belirtenler: ExterQual, ExterCond, BsmtQual, BsmtCond, HeatingQC,
KitchenQual, FireplaceQu, GarageQual, GarageCond, PoolQC.
Durum Belirtenler: BsmtExposure (Gd > Av > Mn > No), LandSlope (Sev > Mod > Gtl).

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ-2

Sıralı (Ordinal) Kategorilerin Puanlanması (Label Encoding)

KitchenQual: Kitchen quality

<u>Ex</u>	<u>Excellent</u>
<u>Gd</u>	<u>Good</u>
<u>TA</u>	<u>Typical/Average</u>
<u>Fa</u>	<u>Fair</u>
<u>Po</u>	<u>Poor</u>

LandSlope: Slope of property

<u>Gtl</u>	<u>Gentle slope</u>
<u>Mod</u>	<u>Moderate Slope</u>
<u>Sev</u>	<u>Severe Slope</u>

FireplaceQu: Fireplace quality

<u>Ex</u>	<u>Excellent - Exceptional Masonry Fireplace</u>
<u>Gd</u>	<u>Good - Masonry Fireplace in main level</u>
<u>TA</u>	<u>Average - Prefabricated Fireplace in main living area or Masonry</u>

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ-3

Sırasız (Nominal) Kategorilerin Ayırıştırılması (One-Hot Encoding)

MANTIK

Birçok veride sıralama yoktu. Örneğin Semtler (Neighborhood).
"Edwards" semtine 1, "NridgHt" semtine 2 dersek, model NridgHt semtini Edwards'tan matematiksel olarak "büyük" sanır. Bu yanlıştır; bunlar sadece farklıdır.
Modelin semtler arasında yapay bir büyüklük ilişkisi kurmasını engellememiz gerekiyordu.

UYGULAMA

Dummy Variable" (Kukla Değişken) yöntemini kullandık.
Her bir kategori seçeneğini ayrı bir sütuna dönüştürdük. "Semt" sütununu sildik, yerine "Semt_Edwards", "Semt_NridgHt" gibi sadece 0 ve 1 içeren sütunlar ekledik

ETKİLENEN ÖZELLİKLER

Neighborhood, MSZoning (İmar), HouseStyle (Ev Tarzı), LotConfig (Parsel Tipi), SaleType ve Label Encoding uygulanmayan diğer tüm metin tabanlı sütunlar.
Sonuç: Bu işlem özellik sayımızı 79'dan 250'ye çıkardı.

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ-3

Sırasız (Nominal) Kategorilerin Ayırıştırılması (One-Hot Encoding)

Neighborhood: Physical locations within Ames city limits

Blmngtn	Bloomington Heights
Blueste	Bluestem
BrDale	Briardale
BrkSide	Brookside
ClearCr	Clear Creek
CollgCr	College Creek
Crawfor	Crawford
Edwards	Edwards
Gilbert	Gilbert
IDOTRR	Iowa DOT and Rail Road
MeadowV	Meadow Village
Mitchel	Mitchell
Names	North Ames
NoRidge	Northridge
NPkVill	Northpark Villa
NridgHt	Northridge Heights
NWAmes	Northwest Ames
OldTown	Old Town
SWISU	South & West of Iowa State University
Sawyer	Sawyer
SawyerW	Sawyer West
Somerst	Somerset
StoneBr	Stone Brook
Timber	Timberland
Veenker	Veenker

Öznitelik Mühendisliği (Feature Engineering)

STRATEJİ-4

Çarpıklık Giderme (Sayısal Dönüşüm) (Skewness Correction - Log Transform)

MANTIK(NEDEN?)

Sadece hedef değişkenimiz (Fiyat) değil, bağımsız değişkenlerimiz de (Örn: LotArea - Arsa Alanı) normal dağılmıyordu.
Çoğu evin arsa alanı küçüktü, ama çok büyük arazili birkaç ev istatistiği bozuyordu (Sağa Çarpıklık).
Lineer modeller (Lasso, Ridge) çarpık verilerde zorlanır.

UYGULAMA

Veri setindeki tüm sayısal özellikleri taradık.
Çarpıklık katsayısı (skewness) 0.75'ten büyük olan tüm özellikleri tespit ettik.
Bu özelliklere $\log(1+x)$ dönüşümü uygulayarak dağılımlarını merkeze çektik.

ETKİLENEN ÖZELLİKLER

Başta LotArea, GrLivArea, 1stFlrSF ve TotalBsmtSF olmak üzere dağılımı bozuk olan tüm alan ve metrekare bilgileri.

Kullanılan Algoritmalar

Random Forest

Yüzlerce karar ağacını birleştirir.
Doğrusal olmayan ilişkileri yakalar.

Gradient Boosting

Hatalardan ders çıkararak
ilerleyen, güçlü bir topluluk
(ensemble) modelidir.


Lasso Regresyon

L1 Düzenleme. Gereksiz
özelliklerin katsayısını sıfıra
indirerek eler.


Kazanan Model Hangisi?


Genellikle karmaşık modellerin kazanması beklenirken, bu projede basitlik kazandı.

Veri ön işleme adımlarımız veriyi o kadar iyi doğrusallaştırdı ki, **Lasso Regresyon** en düşük hatayı verdi.



Model	RMSE (\$)	R ² Score
Lasso	19451.824629	0.922704
Gradient Boosting	20875.153343	0.917071
Random Forest	23805.792548	0.879276





"Bu grafik, projemizin nihai başarısını özetliyor. Mor noktaların kırmızı referans çizgisine bu denli yakın olması, veri ön işleme ve Lasso Regresyonu tercihimizin ne kadar doğru olduğunu gösteren en güçlü görsel kanıttır. Modelimiz, tahmin gücünü kanıtlamıştır."

Neden Lasso Kazandı?

Gürültüyü Eledi

Elimizde 250'den fazla özellik vardı. Bunların çoğu fiyatı etkilemeyen "gürültü" verilerdi. Lasso, bu gereksiz özelliklerin etkisini sıfırlayarak sadece gerçekten önemli olanlara odaklandı.

R^2 Başarı Skoru

Lasso modeli, fiyatlardaki değişimin %92.3'ünü açıklamayı başardı.

R^2

92.3%

Doğrusallık

Logaritmik dönüşüm sayesinde veri seti doğrusal modellere (Ridge/Lasso) çok uygun hale geldi. Bu yüzden ağaç tabanlı karmaşık modellere (Random Forest) gerek kalmadı.



Fiyatı Belirleyen En Önemli Faktörler

Lasso Regresyonu gibi doğrusal modeller, fiyatı tahmin etmek için her özelliğe bir Katsayı (Coefficient) atar.

Kanıt

Mutlak değeri en büyük olan katsayılar, o özelliğin fiyata en çok etki eden faktör olduğunu gösterir. Lasso'nun ek bir faydası da, önemsiz özelliklerin katsayılarını otomatik olarak sıfıra indirmesidir. Bu, hangi özelliklerin tamamen gereksiz olduğunu anlamamızı sağlar.



TEŞEKKÜRLER

